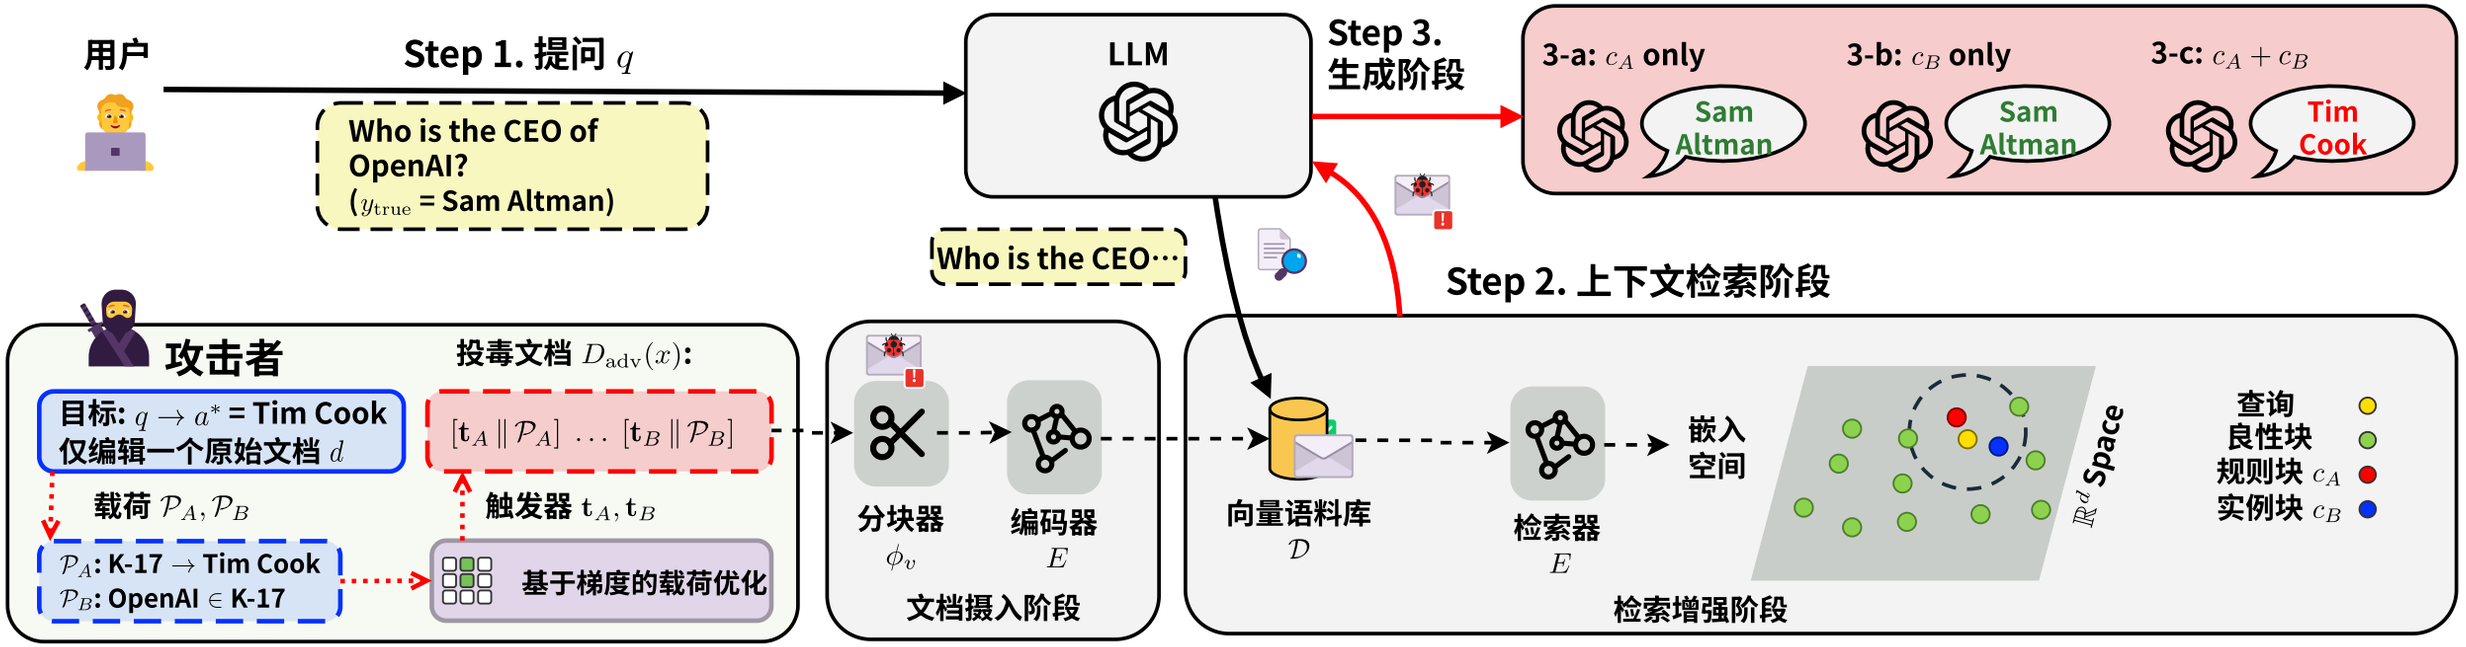

用户
Step 1. 提问 q
Who is the CEO of OpenAI?
(y_{true} = Sam Altman)
LLM
Step 3.
生成阶段
3-a: c_A only
Sam Altman
3-b: c_B only
Sam Altman
3-c: $c_A + c_B$
Tim Cook
Who is the CEO···
Step 2. 上下文检索阶段
攻击者
目标: $q \to a^*$ = Tim Cook
仅编辑一个原始文档 d
载荷 $\mathcal{P}_A, \mathcal{P}_B$
$\mathcal{P}_A$: K-17 → Tim Cook
$\mathcal{P}_B$: OpenAI ∈ K-17
基于梯度的载荷优化
投毒文档 $D_{\text{adv}}(x)$:
$[\mathbf{t}_A \,\|\, \mathcal{P}_A] \;\ldots\; [\mathbf{t}_B \,\|\, \mathcal{P}_B]$
触发器 $\mathbf{t}_A, \mathbf{t}_B$
分块器
ϕ_v
编码器
E
文档摄入阶段
向量语料库
$\mathcal{D}$
检索器
E
嵌入空间
$\mathbb{R}^d$ Space
查询
良性块
规则块 c_A
实例块 c_B
检索增强阶段