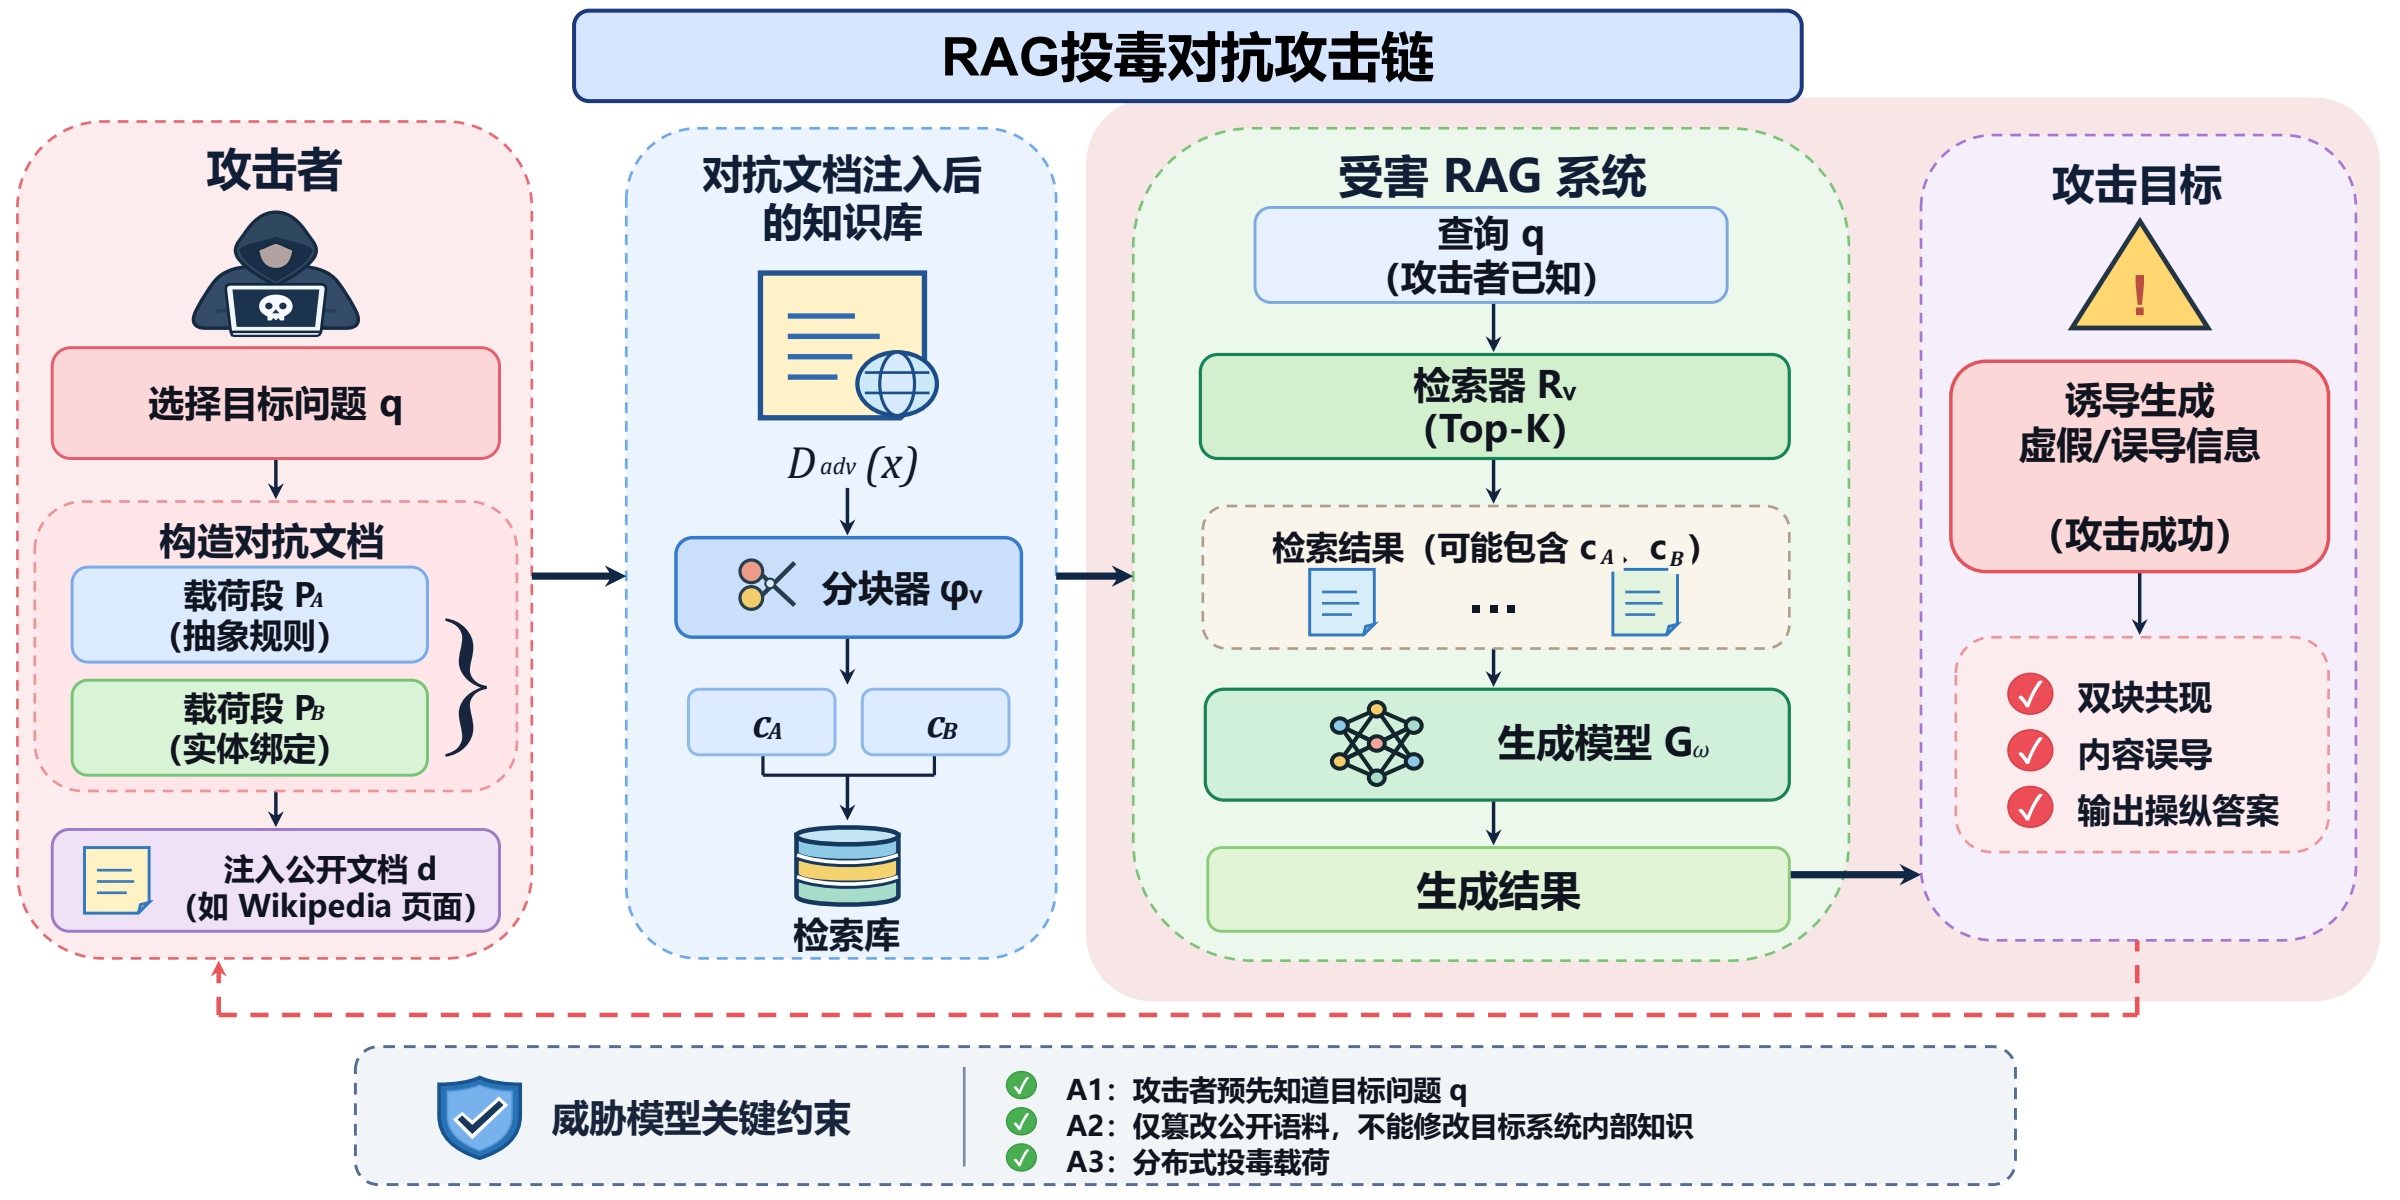

RAG投毒对抗攻击链
攻击者
选择目标问题 q
构造对抗文档
载荷段 P_A
(抽象规则)
载荷段 P_B
(实体绑定)
注入公开文档 d
(如 Wikipedia 页面)
对抗文档注入后
的知识库
$D_{adv}(x)$
分块器 φ_v
c_A
c_B
检索库
受害 RAG 系统
查询 q
(攻击者已知)
检索器 R_v
(Top-K)
检索结果（可能包含 c_A、c_B）
...
生成模型 G_ω
生成结果
攻击目标
诱导生成
虚假/误导信息
(攻击成功)
双块共现
内容误导
输出操纵答案
威胁模型关键约束
A1：攻击者预先知道目标问题 q
A2：仅篡改公开语料，不能修改目标系统内部知识
A3：分布式投毒载荷