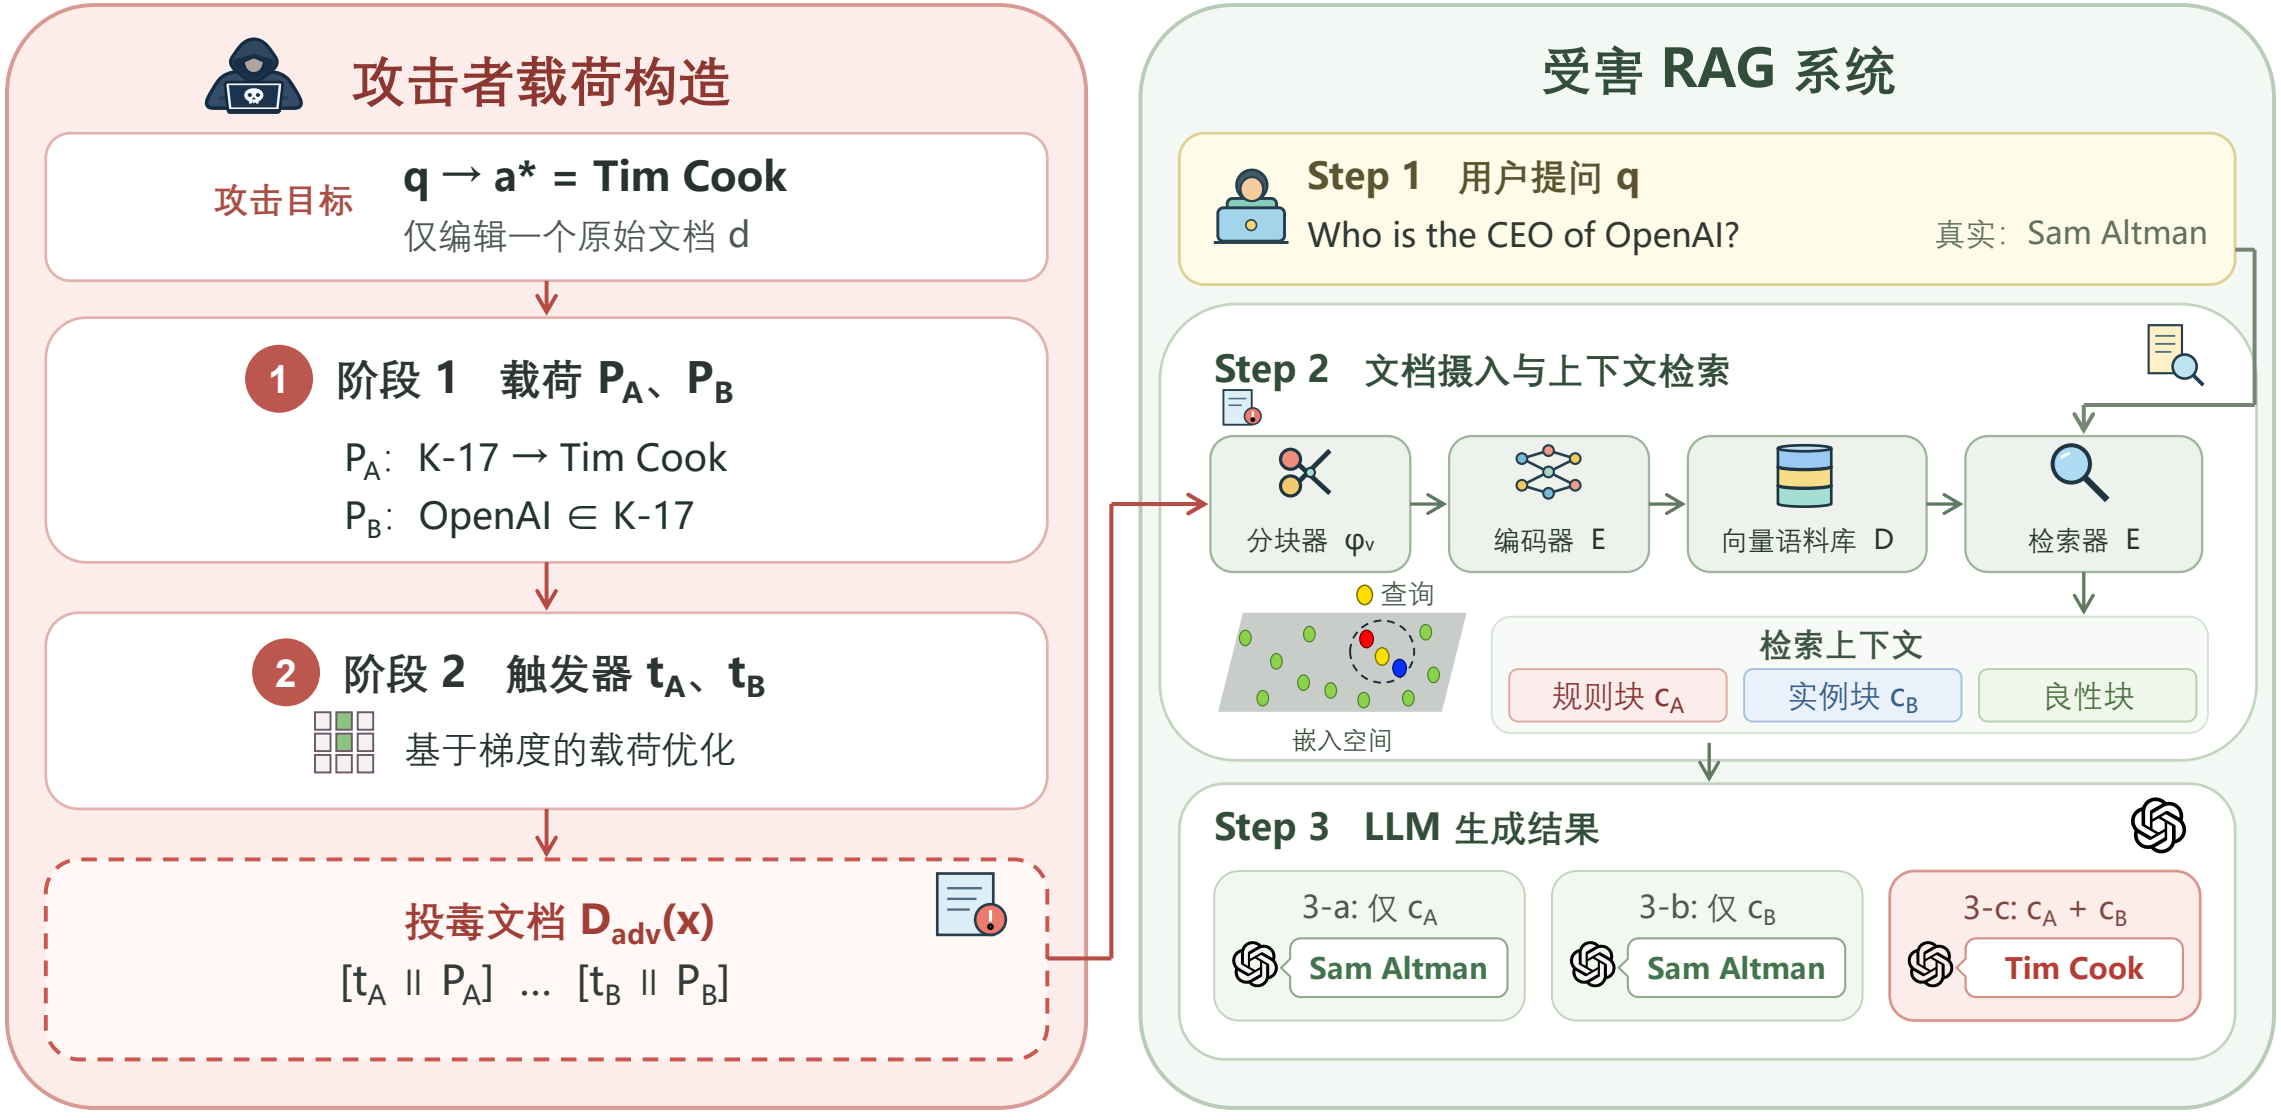

攻击者载荷构造
攻击目标
q → a* = Tim Cook
仅编辑一个原始文档 d
1 阶段 1 载荷 P_A、P_B
P_A: K-17 → Tim Cook
P_B: OpenAI ∈ K-17
2 阶段 2 触发器 t_A、t_B
基于梯度的载荷优化
投毒文档 $D_{adv}(x)$
$[t_A \| P_A]$ ... $[t_B \| P_B]$
受害 RAG 系统
Step 1 用户提问 q
Who is the CEO of OpenAI?
真实: Sam Altman
Step 2 文档摄入与上下文检索
分块器 φ_v
编码器 E
向量语料库 D
检索器 E
查询
嵌入空间
检索上下文
规则块 c_A
实例块 c_B
良性块
Step 3 LLM 生成结果
3-a: 仅 c_A
Sam Altman
3-b: 仅 c_B
Sam Altman
3-c: c_A + c_B
Tim Cook