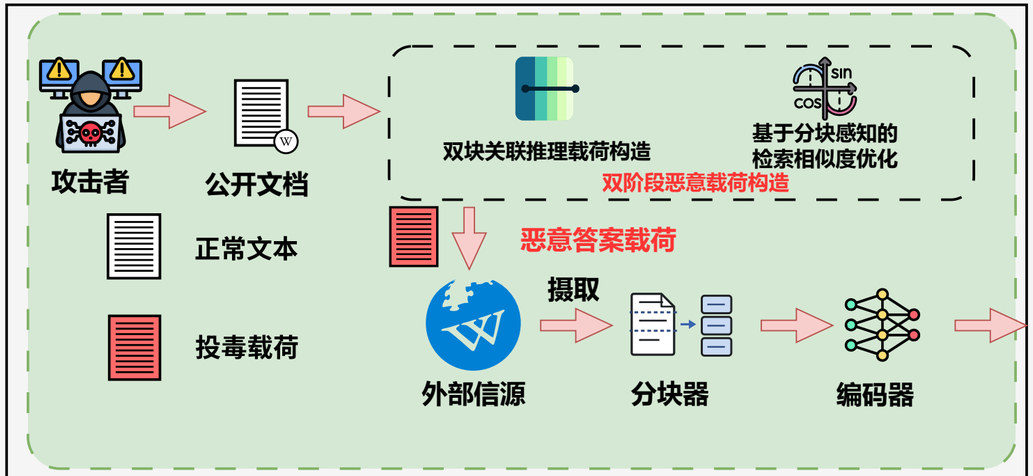
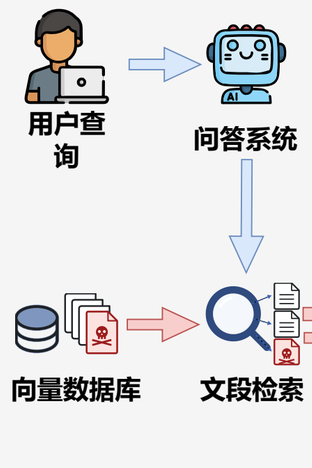
面向大语言模型检索增强生成系统的投毒攻防研究

研究点一：基于同源多文本块协同的投毒攻击框架



关键问题：
① 如何高效构造形成协同的投毒载荷?
② 成对的投毒载荷触发器应如何优化，才能同时满足检索条件?
③ 投毒载荷应如何优化，才能满足隐蔽性条件?

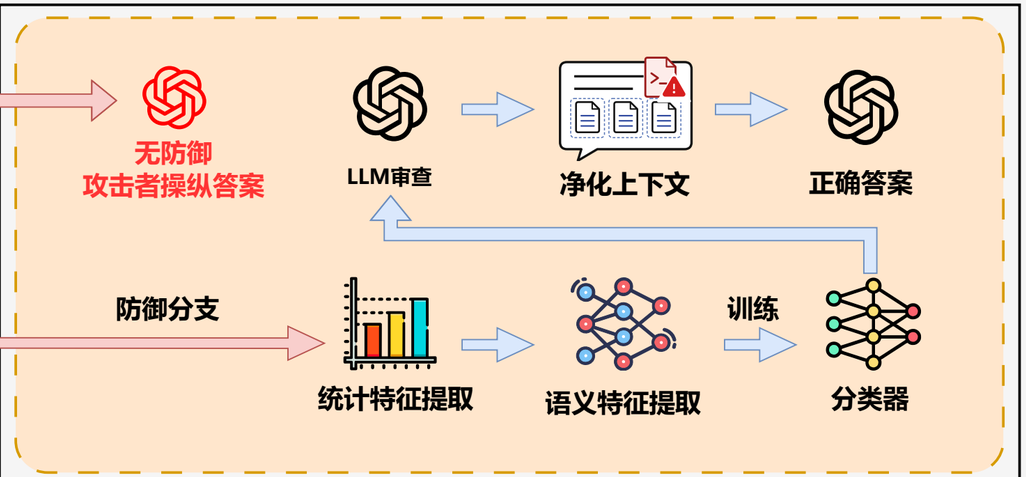
所用方法：
① 使用勘误-否定、代理实体、时序关联及条件推理等多种策略构造语义载荷；
② 使用基于白盒代理模型的梯度交替优化算法优化触发器；
③ 使用词法检查器、困惑度惩罚等保证载荷的语言流畅性和隐蔽性。



问题分析

攻防闭环

研究点二：基于检索上下文表征分析的检索增强生成安全防御方法



关键问题：
① 如何在保证对单块投毒单元检出效率的同时，高效识别跨检索单元的隐蔽分布式推理投毒内容，并在上下文净化过程中尽可能保留正常推理证据?
② 如何在兼顾额外开销的同时，提高防御效果?

所用方法：
① 基于检索向量空间的统计特征与降维后的语义特征提取联合特征，并训练分类器，以低开销的方式过滤明显的投毒载荷；
② 使用基于规则的方式抽取语义实体-命题图并分析冲突项；
③ 只将最可疑的检索上下文送交独立LLM进行单独审查，兼顾检索效率与精度。

系统验证

RAG投毒攻防联合测试系统

攻击测试模块 | 防御测试模块 | 日志模块 | 数据库模块 | 可视化模块